itleHệ thống Phát hiện Xâm nhập (IDS) ứng dụng Trí tuệ Nhân tạo: Phát hiện Tấn công Mạng theo Thời gian Thực bằng Machine Learning trên Dataset CIC-IDS2017

No Title Given

Lê Anh Tuấn[1⋆], Tô Hoàng Đạo[1⋆⋆], and Nguyễn Từ Thanh Duy[1⋆⋆⋆]

Trường Đại học Tôn Đức Thắng (TDTU), TP. Hồ Chí Minh, Việt Nam

Abstract. Mạng lưới doanh nghiệp hiện đại phải đối mặt với bề mặt tấn công ngày càng mở rộng, với các đối thủ sử dụng các kỹ thuật từ các cuộc tấn công DDoS (DDoS) khối lượng lớn đến các cuộc tấn công dò mật khẩu lén lút và các cuộc tấn công tiêm nhiễm lớp web. Các Hệ thống Phát hiện Xâm nhập (IDS) dựa trên chữ ký vẫn hiệu quả với các mối đe dọa đã biết nhưng không thể khái quát hóa đối với các cuộc tấn công mới và đa hình. Bài báo này trình bày một IDS ứng dụng AI áp dụng Machine Learning có giám sát để phân loại Flow mạng trên 13 lớp lưu lượng sử dụng Dataset chuẩn CIC-IDS2017. Chúng tôi thiết kế một quy trình đầu cuối bao gồm lấy mẫu phân tầng, chiến lược lấy mẫu tăng cường SMOTE theo tỷ lệ dựa trên công thức mục tiêu căn bậc hai và huấn luyện so sánh bốn bộ phân loại: LightGBM, XGBoost, Random Forest và Decision Tree. Kết quả thực nghiệm trên tập kiểm tra độc lập gồm 46.838 Flow cho thấy **LightGBM với Proportional SMOTE** đạt Macro-F_1 tốt nhất là **0.9241** và Độ chính xác cân bằng (Balanced Accuracy) là **0.9253**, với sáu trong mười ba lớp đạt mức tuyệt đối $F_1 = 1.00$. Tất cả các mô hình dựa trên cây đều duy trì tốc độ > 30.000 Flow mỗi giây trên phần cứng CPU thông thường, đáp ứng ngân sách độ trễ cho việc triển khai trực tiếp (inline deployment). Chúng tôi xác định các dạng lỗi còn lại—chủ yếu là sự nhầm lẫn giữa các loại Web Attacks phụ và độ tin cậy bị suy giảm của các lớp có hơn 80% mẫu huấn luyện tổng hợp—và thảo luận về các biện pháp giảm thiểu mục tiêu bao gồm các tính năng ở cấp độ Payload và điều chỉnh ngưỡng.

Keywords: Hệ thống Phát hiện Xâm nhập · Machine Learning · CIC-IDS2017 · LightGBM · XGBoost · Random Forest · SMOTE · Mất cân bằng Lớp · An ninh Mạng

1 Giới thiệu

Cảnh quan mối đe dọa mạng toàn cầu đã phát triển mạnh mẽ cả về khối lượng và mức độ tinh vi trong thập kỷ qua. Các doanh nghiệp thường xuyên phải đối mặt với các cuộc tấn công DDoS (DDoS) khối lượng lớn, nhồi nhét thông tin xác thực SSH và FTP bằng brute-force, tiêm nhiễm ứng dụng web, Reconnaissance nội bộ và Beacon ra lệnh và điều khiển (C2) của phần mềm độc hại—thường diễn ra đồng thời và trên các phân đoạn mạng không đồng nhất. Do đó, **Hệ**

⋆ MSSV: 252805005
⋆⋆ MSSV: 252805401
⋆⋆⋆ MSSV: 252805701

thống phát hiện xâm nhập (IDS) là lớp nền tảng của phòng thủ chiều sâu (defense-in-depth), liên tục giám sát lưu lượng và đưa ra cảnh báo khi quan sát thấy hoạt động sai lệch so với các mẫu dự kiến [7].

Các IDS truyền thống được chia thành hai họ lớn: các bộ phát hiện *dựa trên chữ ký (signature-based)* khớp lưu lượng với cơ sở dữ liệu quy tắc được tuyển chọn (ví dụ: Snort, Suricata) và các bộ phát hiện *dựa trên sự bất thường (anomaly-based)* lập mô hình hành vi bình thường và gắn cờ các sai lệch thống kê. Các phương pháp tiếp cận chữ ký rất chính xác nhưng dễ bị phá vỡ—chúng yêu cầu các quy tắc do con người tạo ra và không thể phát hiện các cuộc tấn công zero-day hoặc phần mềm độc hại đa hình có chữ ký bị thay đổi. Các phương pháp tiếp cận dị thường tổng quát hóa tốt hơn nhưng trong lịch sử đã phải chịu tỷ lệ False Positive cao làm quá tải các nhà phân tích [6]. Những hạn chế này thúc đẩy **các IDS dựa trên Machine Learning** học các biểu diễn phân biệt lưu lượng trực tiếp từ dữ liệu được dán nhãn.

Trong dự án này, chúng tôi thiết kế, triển khai và đánh giá một IDS ứng dụng AI để phân loại các Flow mạng trên 13 lớp lưu lượng. Cụ thể, chúng tôi có những đóng góp sau:

1. **Một quy trình ML đầu cuối (end-to-end)** từ các đặc trưng CICFlowMeter thô đến phân loại trên từng Flow, bao gồm lấy mẫu phân tầng, Lấy mẫu tăng cường SMOTE theo tỷ lệ và huấn luyện so sánh bốn bộ phân loại trên Dataset chuẩn **CIC-IDS2017** [1].
2. **Một nghiên cứu so sánh** bốn mô hình học—LightGBM [9], XGBoost [4], Random Forest [3] và Decision Tree—bao gồm các lớp lưu lượng DDoS, PortScan, Brute-Force, DoS, Web Attacks, Bot và bình thường (benign).
3. **Một nghiên cứu cắt bỏ (ablation study)** phân lập sự đóng góp của Proportional SMOTE và xác định các chế độ lỗi hệ thống (nhầm lẫn Web Attacks, độ tin cậy của Rare_Attack) vốn có trong phân loại mức độ Flow (flow-level).
4. **Thảo luận về việc triển khai** bao gồm trôi dạt khái niệm (concept drift), độ mạnh mẽ đối kháng (adversarial robustness) và các lộ trình Online/Continuous Learning.

Kết quả nổi bật của chúng tôi là **LightGBM với Proportional SMOTE** đạt được Macro-F_1 là 0.9241 trên tập kiểm tra độc lập với sáu trong mười ba lớp đạt $F_1 = 1.00$ hoàn hảo, trong khi duy trì thông lượng > 30.000 Flow mỗi giây trên phần cứng CPU thông thường.

Phần còn lại của báo cáo này được tổ chức như sau. Phần 2 xem xét công thức bài toán IDS, Dataset CIC-IDS2017 và nền tảng Machine Learning. Phần 3 mô tả quy trình ML đầu cuối và bốn mô hình ứng viên. Phần 4 trình bày các kết quả định lượng. Phần 5 thảo luận về các hạn chế và hướng phát triển trong tương lai. Phần 6 là kết luận.

2 Cơ sở Lý thuyết

Phần này xem xét kiến thức chuyên ngành và cơ sở kỹ thuật cần thiết để theo dõi phần còn lại của bài báo. Chúng tôi bắt đầu với phần giới thiệu về lưu

lượng mạng và phân loại các cuộc tấn công dựa trên mạng (Phần 2.1), sau đó mô tả Dataset CIC-IDS2017 và ý nghĩa của các đặc trưng cấp độ Flow của nó (Phần 2.2). Phần 2.3 tóm tắt các kỹ thuật tiền xử lý dữ liệu—bao gồm xử lý mất cân bằng lớp và chuẩn hóa—mà sau này chúng tôi áp dụng để chuẩn bị Dataset cho việc huấn luyện. Cuối cùng, Phần 2.4 phác thảo chủ nghĩa hình thức Machine Learning liên quan đến bài toán phân loại đa lớp của chúng tôi và các số liệu đánh giá được sử dụng trong suốt các thử nghiệm.

2.1 Lưu lượng mạng và Phân loại tấn công

Lưu lượng mạng: Các Packet và Flow. Ở cấp độ thấp nhất, các mạng máy tính trao đổi thông tin dưới dạng các *Packet*—các đơn vị dữ liệu rời rạc được trang bị các tiêu đề giao thức (Ethernet, IP, TCP/UDP) và Payload. Việc chụp các Packet thô thường được lưu trữ ở định dạng **PCAP** (Packet CAPture) được sử dụng rộng rãi, giúp bảo toàn độ trung thực từng byte của lưu lượng được quan sát. Mặc dù phân tích cấp độ Packet rất hữu ích để kiểm tra sâu, nhưng nó không thực tế đối với mô hình hóa thống kê vì các Packet riêng lẻ nhiễu và có kích thước thay đổi.

Đối với phát hiện xâm nhập, đơn vị phân tích tự nhiên là *Flow*. Một Flow là sự trao đổi hai chiều của các Packet chia sẻ cùng một **bộ 5 (5-tuple)**—IP nguồn, IP đích, cổng nguồn, cổng đích và giao thức truyền tải—trong một khoảng thời gian giới hạn. Một công cụ như CICFlowMeter [10] đưa vào các tệp PCAP và xuất ra một hàng cho mỗi Flow, tóm tắt nó bằng các số liệu thống kê như thời lượng, số lượng Packet, thời gian xuất hiện (inter-arrival times) và phân phối cờ TCP. Biểu diễn cấp độ Flow là phương thức đầu vào được sử dụng xuyên suốt bài báo này.

Phân loại các cuộc tấn công mạng. Chúng tôi tập trung vào các danh mục tấn công có trong CIC-IDS2017, được nhóm theo hành vi có thể quan sát được của chúng trong thống kê Flow:

Port Scan / Network Scan. Kẻ tấn công thăm dò các máy chủ hoặc cổng để lập bản đồ các dịch vụ bị lộ. Các công cụ như nmap và masscan phát ra nhiều nỗ lực kết nối ngắn hạn đến một tập hợp lớn các đích, tạo ra các Flow có số lượng Packet rất nhỏ nhưng tốc độ xuất hiện cao bất thường.

DoS/DDoS. Các cuộc tấn công khối lượng lớn cố gắng làm cạn kiệt tài nguyên mạng, truyền tải hoặc ứng dụng. Chúng biểu hiện dưới dạng các đợt Flow (bursts of flows) hướng tới một đích duy nhất, với phân phối kích thước Packet bị lệch và các mẫu cờ TCP bất thường (ví dụ: SYN flood, ACK flood, HTTP flood thông qua các công cụ như hping3 hoặc GoldenEye).

Brute-Force. Các cuộc tấn công đoán thông tin xác thực nhắm vào các điểm cuối đăng nhập SSH, FTP và web (ví dụ: Patator, Hydra). Chúng xuất hiện dưới dạng nhiều Flow ngắn, lặp đi lặp lại đến cùng một cổng đích, thường không xác thực được và tạo ra các phiên TCP có thời lượng ngắn đặc trưng.

Web Attacks. SQL injection, cross-site scripting (XSS) và command injection nhắm mục tiêu vào lớp HTTP. Ở cấp độ Flow, chúng khó phát hiện hơn: chỉ một phần nhỏ byte khác với duyệt web bình thường, do đó, kỹ thuật Feature Extraction trên thống kê dẫn xuất từ Payload hoặc entropy URI sẽ hữu ích.

Xâm nhập và Beacon ra lệnh và điều khiển của Malware (C2). Sau khi một máy chủ bị xâm phạm, nó thường *Beacon* trở lại một máy chủ do kẻ tấn công kiểm soát theo các khoảng thời gian đều đặn. Dấu hiệu ở cấp độ Flow là lưu lượng có khối lượng thấp nhưng mang tính chu kỳ cao, thường qua các kênh được mã hóa.

Lưu lượng Botnet. Các máy chủ bị nhiễm phối hợp với một bộ điều khiển thông qua IRC, HTTP(S) hoặc các mạng lưới ngang hàng (peer-to-peer). Các Flow botnet thường chia sẻ các dấu vân tay thống kê tương tự trên nhiều nguồn bị xâm phạm.

Mỗi lớp tấn công này định hình phân phối kết hợp (joint distribution) của các đặc trưng Flow theo cách khác nhau, và đây chính xác là những gì một bộ phân loại được học khai thác.

IDS dựa trên chữ ký vs. Dựa trên bất thường vs. Dựa trên ML. Các Hệ thống Phát hiện Xâm nhập cổ điển được phân loại rộng rãi thành *dựa trên chữ ký*—khớp lưu lượng với các quy tắc thủ công (ví dụ: Snort, Suricata) [11]—hoặc *dựa trên bất thường*—mô hình hóa hành vi bình thường và gắn cờ các sai lệch. Các phương pháp chữ ký chính xác với các mối đe dọa đã biết nhưng mù quáng trước các biến thể mới; các phương pháp bất thường tổng quát hóa tốt hơn nhưng trong lịch sử phải chịu tỷ lệ False Positive cao. Các IDS dựa trên Machine Learning chiếm một vị trí trung gian bằng cách *học* các biểu diễn Flow có tính phân biệt trực tiếp từ lưu lượng được gắn nhãn, cung cấp khả năng tổng quát hóa tốt hơn so với chữ ký đồng thời mang lại tỷ lệ False Positive thấp hơn so với phát hiện bất thường thuần túy [7].

2.2 Dataset CIC-IDS2017

Tổng quan và Phương pháp thu thập. Dataset **CIC-IDS2017**, do Viện An ninh Mạng Canada phát hành, được xây dựng đặc biệt để giải quyết các thiếu sót nổi tiếng của các bộ tiêu chuẩn cũ hơn (KDD'99, NSL-KDD) như các bản ghi dư thừa, các vector tấn công lỗi thời và các mẫu lưu lượng phi thực tế [1,2]. Nó được thu thập trong *năm ngày làm việc* (Thứ Hai đến Thứ Sáu, ngày 3–7 tháng 7 năm 2017) trên một testbed chuyên dụng bao gồm một mạng nạn nhân có 10 máy chủ chạy Windows, Linux và macOS, và một mạng tấn công có 4 máy chạy các chiến dịch được tạo kịch bản. Lưu lượng nền bình thường được tạo thông qua framework *B-Profile*, lập mô hình hành vi thống kê của người dùng trên các giao thức HTTP, HTTPS, FTP, SSH và email.

Các bản ghi PCAP thô được xử lý bằng bộ công cụ CICFlowMeter [10], xuất ra một hàng cho mỗi Flow hai chiều và gắn nhãn cho mỗi Flow với lớp thực tế (ground-truth) bắt nguồn từ lịch trình tấn công. Kho ngữ liệu kết quả chứa

khoảng **2,83 triệu Flow được gắn nhãn**, phân bổ trên một lớp bình thường (benign) và mười bốn lớp tấn công (thường được gộp thành bảy lớp tổng hợp để mô hình hóa).

Ngữ nghĩa đặc trưng. CIC-IDS2017 cung cấp **78 đặc trưng số** cho mỗi Flow (cộng với nhãn). Cho mục đích của báo cáo này, chúng tôi nhóm chúng thành bốn họ có ý nghĩa về mặt ngữ nghĩa:

Mô tả cấp độ Flow (Flow-level descriptors). `Flow Duration`, `Flow Bytes/s`, `Flow Packets/s`, `Total Fwd/Bwd Packets`, `Total Length of Fwd/Bwd Packets`. Những yếu tố này nắm bắt quy mô và tốc độ tổng thể của cuộc trao đổi—các giá trị lớn chỉ ra lưu lượng khối lượng lớn như DDoS hoặc truyền tệp; giá trị gần bằng 0 gợi ý các cuộc thăm dò Reconnaissance.

Thống kê kích thước Packet. `Fwd/Bwd Packet Length Min, Max, Mean, Std`, `Packet Length Variance`, `Min/Max Packet Length`. Phân phối của các kích thước Packet dùng để phân biệt, ví dụ, các trận lụt SYN Packet ngắn từ truyền tải khối lượng lớn có Packet dài.

Thời gian xuất hiện (Inter-arrival times - IAT). `Flow IAT Mean/Std/Max/Min`, `Fwd IAT Total/Mean/Std`, `Bwd IAT Total/Mean/Std`, `Active/Idle Mean/Std`. Các đặc trưng thời gian là tín hiệu mạnh nhất đối với Beacon định kỳ (C2), các vòng lặp brute-force và quét chậm (low-and-slow scans).

Số lượng cờ TCP và tiêu đề. `SYN/ACK/FIN/RST/PSH/URG Flag Count`, `Fwd/Bwd PSH/URG Flags`, `Fwd/Bwd Header Length`. Việc phân phối cờ đặc biệt nhiều thông tin để phát hiện các kết nối mở một nửa (half-open connections), quét (scans) và bắt tay định dạng sai (malformed handshakes).

Table 1. Phân phối lớp tổng hợp của CIC-IDS2017 (tương đối).

Lớp	**Số Flow**	**%**
BENIGN	2.273.097	80,30
DDoS	128.027	4,52
PortScan	158.930	5,62
DoS Hulk	231.073	8,16
DoS GoldenEye	10.293	0,36
DoS slowloris / Slowhttptest	11.420	0,40
FTP-Patator / SSH-Patator	13.835	0,49
Web Attack (Brute/XSS/SQLi)	2.180	0,08
Bot	1.966	0,07
Infiltration	36	0,0013
Heartbleed	11	0,0004
Tổng cộng	**2.830.868**	**100**

Số liệu thống kê và Thách thức của Dataset. Bảng 1 tóm tắt phân phối các lớp. Hai đặc tính chi phối việc thảo luận mô hình hóa. Thứ nhất, Dataset **mất cân bằng (imbalanced) nghiêm trọng**: chỉ riêng lớp bình thường (benign) đã chiếm $\approx 80\%$ tổng số Flow, trong khi các lớp như `Heartbleed` và `Infiltration` chứa ít hơn một trăm mẫu mỗi lớp. Do đó, việc huấn luyện ngây thơ sẽ tạo ra các bộ phân loại mặc định dự đoán `BENIGN` và đạt được độ chính xác tổng thể cao một cách lừa dối trong khi hoàn toàn thất bại trên các lớp tấn công thiểu số quan trọng nhất. Thứ hai, Feature Set chứa một số ít cột có các giá trị không xác định (`NaN`, $\pm\infty$) do các trường hợp biên trong trình tính toán Flow tạo ra (ví dụ: chia cho số không đối với các Flow Packet đơn) và một số ít cột có phương sai bằng không phải được loại bỏ. Những vấn đề này thúc đẩy quy trình tiền xử lý được mô tả tiếp theo.

2.3 Tiền xử lý Dữ liệu

Các bản ghi cấp độ Flow thô không thể được tiêu thụ trực tiếp bởi hầu hết các thuật toán học. Chúng tôi giải quyết bốn mối quan tâm về tiền xử lý: làm sạch dữ liệu, chuẩn hóa, mã hóa nhãn và xử lý mất cân bằng lớp.

Làm sạch Dữ liệu. Chúng tôi loại bỏ các hàng chứa các giá trị `NaN` hoặc $\pm\infty$, loại bỏ các Flow trùng lặp chính xác và loại bỏ các cột có phương sai bằng 0. Sau khi làm sạch, khoảng 99,6% trong số 2,83 triệu bản ghi ban đầu vẫn còn.

Chuẩn hóa và Mã hóa Nhãn. Các đặc trưng của CIC-IDS2017 trải rộng trên nhiều cấp độ lớn (orders of magnitude). Các bộ học dựa trên cây (Random Forest, XGBoost, LightGBM) bất biến với sự thay đổi tỷ lệ đơn điệu và chỉ yêu cầu bộ chia tỷ lệ (scaler) được khớp trên tập huấn luyện và áp dụng đóng băng (frozen) cho dữ liệu kiểm tra. Chúng tôi sử dụng `StandardScaler` (chuẩn hóa Z-score) làm mặc định. Các nhãn phân loại được mã hóa thành các số nguyên thông qua `LabelEncoder` của scikit-learn chỉ được khớp trên các nhãn huấn luyện.

Xử lý Mất cân bằng Lớp. CIC-IDS2017 bị chi phối bởi lưu lượng bình thường (benign) ($\approx 80\%$); các mô hình được huấn luyện ngây thơ sẽ sụp đổ thành bộ phân loại dự đoán `BENIGN` tầm thường. Hai chiến lược bổ sung được kết hợp trong quy trình của chúng tôi:

Trọng số nhạy cảm với chi phí (Cost-sensitive weighting). Tất cả các mô hình được huấn luyện với `class_weight='balanced'`, gán lại trọng số cho mỗi mẫu huấn luyện theo tần suất nghịch đảo của lớp của nó. Phương pháp này chi phí thấp và không yêu cầu thay đổi dữ liệu.

Lấy mẫu tăng cường SMOTE [5]. Các lớp thiểu số được tăng cường với các mẫu tổng hợp được tạo bằng cách nội suy giữa một mẫu thuộc lớp thiểu số và một trong k láng giềng gần nhất của nó trong Feature Space:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_j - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1). \tag{1}$$

Chúng tôi áp dụng Proportional SMOTE (Phần 4.1) *chỉ vào tập huấn luyện*, để các số liệu kiểm tra được báo cáo phản ánh sự phân phối hoạt động không được tăng cường.

2.4 Cơ sở Machine Learning

Các họ mô hình ứng viên. Chúng tôi đánh giá bốn bộ học bao gồm phổ cây quyết định (decision-tree) và tăng cường (boosting) cổ điển:

Random Forest (RF) [3] là một tập hợp các cây quyết định được huấn luyện trên các mẫu bootstrap với việc lấy mẫu con các đặc trưng tại mỗi lần phân tách. Nó mạnh mẽ trước các giá trị ngoại lai và bất biến với việc đổi tỷ lệ đặc trưng đơn điệu.

XGBoost [4] xây dựng một tập hợp cộng gộp các cây nông được khớp tuần tự với các giả thặng dư (pseudo-residuals) của mô hình hiện tại. Nó mang lại kết quả tiên tiến trên dữ liệu dạng bảng và hỗ trợ các mục tiêu được điều chuẩn cho các mục tiêu mất cân bằng.

LightGBM [9] là một framework tăng cường gradient dựa trên biểu đồ (histogram-based) phát triển các cây theo chiều lá (leaf-wise) thay vì theo mức (level-wise), giảm thời gian huấn luyện và bộ nhớ. Chiến lược phân chia biểu đồ của nó làm cho nó đặc biệt hiệu quả trên các Feature Matrix lớn và nhạy cảm với các mẫu SMOTE tổng hợp gần ranh giới các lớp.

Cây quyết định (Decision Tree - DT) là một cây CART duy nhất chưa được cắt tỉa, được đưa vào dưới dạng giới hạn dưới có thể diễn giải được, nhằm làm nổi bật giá trị gia tăng của việc sử dụng tập hợp (ensembling).

Chia tập Huấn luyện / Kiểm tra. Chúng tôi sử dụng phân tách phân tầng **80/20** (random seed 42): 80% để huấn luyện (bao gồm cả tăng cường SMOTE) và 20% làm tập kiểm tra độc lập được báo cáo chính xác một lần.

Các số liệu Đánh giá. Vì sự phân phối lớp vẫn bị lệch nặng sau khi lấy mẫu, **Macro-F_1** là tiêu chí lựa chọn mô hình chính—nó đánh trọng số mọi lớp như nhau bất kể số lượng mẫu. Chúng tôi cũng báo cáo Weighted-F_1, ROC-AUC (macro one-vs-rest), Độ chính xác cân bằng (Balanced Accuracy) và MCC. Nếu chỉ dùng Accuracy thì sẽ gây hiểu lầm: một bộ phân loại chỉ dự đoán `BENIGN` tầm thường đạt được độ chính xác $\approx 80\%$ trong khi phát hiện được 0 cuộc tấn công.

Điểm F_1 cho mỗi lớp có nguồn gốc từ precision và recall tiêu chuẩn:

$$F_{1,c} = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}, \qquad \text{Macro-}F_1 = \frac{1}{C}\sum_{c=1}^{C} F_{1,c}. \tag{2}$$

3 Hệ thống Đề xuất: Quy trình IDS dựa trên ML

Phần 2 đã thiết lập các thành phần khái niệm cần thiết cho nhiệm vụ. Bây giờ chúng ta hợp nhất chúng thành một hệ thống cụ thể: một bộ phân loại đa lớp cấp độ Flow được huấn luyện trên CIC-IDS2017 và được triển khai phía sau một công cụ suy luận Flow (streaming inference engine). Phân hệ 3.1 chính thức hóa bài toán học và các ràng buộc hoạt động của nó; Phân hệ 3.2 mô tả quy trình đầu cuối (end-to-end); Các phân hệ 3.3 và 3.4 trình bày chi tiết về kỹ thuật Feature Extraction và thiết kế mô hình; Phân hệ 3.5 chỉ định quy trình huấn luyện bao gồm mã giả; cuối cùng, Phân hệ 3.6 mô tả công cụ suy luận thời gian thực tiêu thụ các mô hình được huấn luyện trong thực tế.

3.1 Phát biểu Bài toán

Chúng tôi tiếp cận việc phát hiện xâm nhập như một bài toán *phân loại đa lớp, cấp độ Flow, có giám sát* được giải quyết trong thời gian gần thực. Gọi $\mathcal{F}$ biểu thị quần thể các Flow mạng hai chiều được tạo bởi trình trích xuất CICFlowMeter trên một mạng được giám sát. Mỗi Flow $\mathbf{x} \in \mathcal{F}$ được tóm tắt bằng một Feature Vector $\mathbf{x} \in \mathbb{R}^d$ với $d = 78$ trong lược đồ CIC-IDS2017 gốc (được mở rộng trong Phần 3.3). Không gian nhãn là $\mathcal{Y} = \{0, 1, \ldots, C-1\}$, trong đó lớp 0 biểu thị lưu lượng `BENIGN` (bình thường) và $C-1$ lớp còn lại tương ứng với các danh mục tấn công tổng hợp được liệt kê trong Bảng 1.

IDS phải học một bộ phân loại $f_h eta : \mathbb{R}^d o \mathcal{Y}$ từ một kho ngữ liệu huấn luyện được gắn nhãn $\mathcal{D}_{\text{train}} \subset \mathcal{F} \times \mathcal{Y}$ để giảm thiểu rủi ro dự kiến trên phân phối Flow cơ bản. Hai chế độ hoạt động cùng tồn tại:

Huấn luyện ngoại tuyến (Offline training). $f_h eta$ được khớp trên một bản chụp tĩnh, được gắn nhãn đầy đủ. Bước huấn luyện không có ràng buộc về thời gian thực và được phép sử dụng từ hàng chục phút đến vài giờ tính toán, bao gồm kiểm tra chéo phân tầng và tìm kiếm siêu tham số.

Suy luận trực tuyến (Online inference). Khi triển khai, $f_h eta$ nhận một Flow dữ liệu liên tục các Flow $\mathbf{x}_1, \mathbf{x}_2, \ldots$ do trình trích xuất Flow trực tiếp tạo ra. Đối với mỗi $\mathbf{x}_t$ đến, hệ thống phải đưa ra một dự đoán $\hat{y}_t = f_h eta(\mathbf{x}_t)$ trong một ngân sách độ trễ nghiêm ngặt trên mỗi Flow để các hành động cảnh báo và chặn ở hạ lưu vẫn kịp thời.

Các Ràng buộc Hoạt động. IDS được đề xuất nhắm đến các yêu cầu sau, bắt nguồn từ các kịch bản triển khai trực tiếp (inline) điển hình trên các gateway biên của doanh nghiệp:

Chất lượng phát hiện. Macro-F_1 trên tất cả C lớp phải đạt ít nhất 0.95 trên tập kiểm tra độc lập, đảm bảo rằng các danh mục tấn công thiểu số như `Bot` hoặc `Web Attack` không bị đánh đổi ngầm để lấy độ chính xác của lưu lượng bình thường.

Tỷ lệ False Positive (FPR). FPR trên các Flow bình thường không được vượt quá 1%. Vượt qua ngưỡng này, lượng cảnh báo sẽ làm quá tải các nhà

phân tích con người và tạo ra sự mệt mỏi vì cảnh báo, đây là chế độ lỗi hoạt động chủ đạo của các đợt triển khai IDS trong thế giới thực.

Độ trễ mỗi Flow. Độ trễ suy luận đầu cuối—được đo từ lúc trình trích xuất Flow phát ra một bản ghi Flow hoàn chỉnh đến lúc dự đoán có sẵn cho các tác vụ hạ lưu—không được vượt quá 10 ms ở phân vị thứ 99 trên phần cứng thông thường (CPU x86 8 lõi, không có GPU).

Thông lượng. Thông lượng duy trì phải đạt ít nhất 10^4 Flow mỗi giây trên một worker suy luận duy nhất, mức này đủ cho một liên kết 10 Gbps với kích thước Flow trung bình đại diện cho CIC-IDS2017.

Dấu chân tài nguyên. Mô hình được tuần tự hóa, các tạo tác (artefacts) của bộ chia tỷ lệ/mã hóa và các bộ đệm đặc trưng thời gian chạy phải cùng nhau chiếm ít hơn 512 MB bộ nhớ thường trú (resident memory), cho phép triển khai đồng thời với trình trích xuất Flow trên cùng một máy chủ gateway.

Giả định và Các mục tiêu không hướng tới. Chúng tôi giả định rằng trình trích xuất Flow thượng nguồn tạo ra các bản ghi đặc trưng hoàn chỉnh, được định dạng tốt với độ lệch (skew) có giới hạn giữa huấn luyện và phục vụ (*không* xử lý trôi dạt khái niệm trong phiên bản hiện tại; xem Phần 2.1 để thảo luận liên quan). Chúng tôi cũng giả định rằng tập huấn luyện đại diện cho hỗn hợp lưu lượng hoạt động; sự thay đổi phân phối đáng kể sẽ làm mất hiệu lực mô hình được khớp ngoại tuyến và thúc đẩy các phần mở rộng học liên tục được thảo luận trong phần kết luận của chúng tôi. Việc chủ động lẩn tránh đối kháng—nơi những kẻ tấn công cố tình tạo ra các Flow để bị phân loại sai—được thừa nhận nhưng nằm ngoài phạm vi của báo cáo này.

3.2 Tổng quan Kiến trúc Hệ thống

IDS được đề xuất được tổ chức thành một quy trình phân đoạn, trong đó mỗi thành phần đưa ra một hợp đồng dữ liệu hẹp cho thành phần tiếp theo, cho phép huấn luyện ngoại tuyến và suy luận trực tuyến chia sẻ logic tiền xử lý và kỹ thuật Feature Extraction giống hệt nhau:

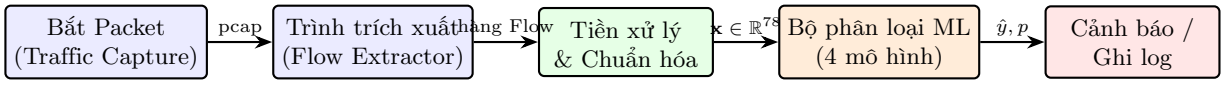

Fig. 1. Quy trình IDS đầu cuối. Các giai đoạn tiền xử lý (màu xanh lá cây) và mô hình (màu cam) được chia sẻ giữa đường dẫn huấn luyện ngoại tuyến và đường dẫn suy luận trực tuyến.

Bắt Packet (Traffic Capture) phản chiếu các Packet thô từ cổng SPAN và ghi chúng vào bộ đệm PCAP cuốn chiếu (rolling PCAP buffer). **Trình trích xuất Flow (Flow Extractor)** (CICFlowMeter [10]) nhóm các Packet thành các Flow hai chiều và xuất ra một hàng có 78 đặc trưng cho mỗi Flow. **Tiền xử**

lý & Chuẩn hóa loại bỏ các hàng có `NaN`/$\pm\infty$, áp dụng `StandardScaler` đã đóng băng và mã hóa các nhãn. **Bộ phân loại ML** tính điểm Feature Vector đã chuẩn hóa và đưa ra một lớp dự đoán cùng độ tin cậy tùy chọn. **Cảnh báo / Ghi log** chuyển tiếp các dự đoán không phải `BENIGN` tới SIEM và ghi lại tất cả các dự đoán để theo dõi trôi dạt ngoại tuyến.

3.3 Kỹ thuật Feature Extraction

78 đặc trưng số do CICFlowMeter tạo ra được sử dụng nguyên trạng trong các thử nghiệm của chúng tôi. Việc loại bỏ các cột siêu dữ liệu định danh Flow (`Flow ID`, IP nguồn/đích, `Timestamp`) để lại một Feature Matrix $\mathbf{X} \in \mathbb{R}^{N\times 78}$ mà các cột của nó bao gồm bốn nhóm có ý nghĩa về mặt ngữ nghĩa: mô tả cấp độ Flow (thời lượng, số byte/số Packet), thống kê kích thước Packet (min/max/mean/std), thời gian xuất hiện (IAT mean/std ở cả hai hướng) và số lượng cờ TCP (SYN, ACK, FIN, RST, PSH, URG).

Cách tiếp cận "chỉ các đặc trưng thô" này là có chủ đích. Như đã lưu ý trong Phần 2.4, các bộ học dựa trên cây bất biến với việc đổi tỷ lệ cột đơn điệu và không yêu cầu các đặc trưng tương tác do con người thiết kế để đạt được hiệu suất mạnh mẽ trên dữ liệu dạng bảng. Quá trình tiền xử lý duy nhất được áp dụng trước bộ học là `StandardScaler` được khớp trên tập huấn luyện, giúp căn giữa và chuẩn hóa mỗi cột thành phương sai đơn vị. Cả bốn mô hình ứng viên đều tiêu thụ cùng một biểu diễn $\mathbb{R}^{78}$ này.

Nghiên cứu trong tương lai có thể khám phá các đặc trưng phái sinh như tỷ lệ số lượng Packet chuyển tiếp/ngược lại (forward/backward packet-count ratios) hoặc entropy Shannon của phân phối độ dài Packet, cả hai đều cho thấy mức tăng khiêm tốn trên mỗi lớp đối với các lớp thiểu số (`Bot`, `Beacon C2`) trong các tài liệu liên quan. Chúng tôi để điều này cho các nghiên cứu trong tương lai nhằm giữ cho quy trình hiện tại đơn giản và có thể tái tạo.

3.4 Thiết kế Mô hình

Phần 2.4 đã giới thiệu bốn bộ học ứng viên ở cấp độ khái niệm. Bây giờ chúng tôi chỉ định các cấu hình cụ thể của chúng được sử dụng trong đánh giá thực nghiệm của Phần 4. Tất cả các mô hình đều tiêu thụ cùng một Feature Vector 78 chiều do CICFlowMeter tạo ra và đưa ra dự đoán phân loại trên $C = 13$ lớp.

Random Forest (RF). Sử dụng `RandomForestClassifier` của scikit-learn với `n_estimators`=200, `max_features`=$\sqrt{d}$, `class_weight`=`balanced_subsample`, độ sâu không giới hạn. Tùy chọn `balanced_subsample` gán lại trọng số cho mỗi mẫu bootstrap sao cho các lớp thiểu số đóng góp theo tỷ lệ mà không tính đúp các mẫu do SMOTE tạo ra.

XGBoost. `XGBClassifier` với `objective`=`multi:softprob`, `n_estimators`=500, `max_depth`=8, `learning_rate`=0.1, `subsample`=0.8, `colsample_bytree`=0.8, điều chuẩn L2 (L2 regularisation) $\lambda = 1.0$, tìm kiếm phân tách bằng biểu đồ

(`tree_method=hist`). Mất cân bằng lớp được xử lý qua vector trọng số mẫu $w_i = N/(C \cdot n_{y_i})$ áp dụng bổ sung cho SMOTE.

LightGBM. `LGBMClassifier` với `n_estimators`=500, `max_depth`=8, `learning_rate`=0.1, `num_leaves`=63, `is_unbalance=True`. Chiến lược phát triển theo chiều lá (leaf-wise) và tạo thùng (binning) dựa trên biểu đồ của LightGBM giúp nó nhanh hơn đáng kể so với XGBoost trên các Feature Matrix rộng và nhạy cảm hơn với các mẫu tổng hợp gần ranh giới lớp—một lợi thế trên dữ liệu huấn luyện được tăng cường bằng SMOTE.

Cây quyết định (Decision Tree - DT). Sử dụng `DecisionTreeClassifier` của scikit-learn với độ sâu không giới hạn, tiêu chí tạp chất Gini và `class_weight=balanced`. Nó đóng vai trò như một giới hạn dưới nhanh chóng, có thể diễn giải được để định lượng giá trị gia tăng của việc sử dụng tập hợp (ensembling).

Tại sao lại là Bốn Mô hình? Bốn bộ học cho phép thực hiện ba so sánh có mục tiêu: (i) cây đơn vs. lấy mẫu có hoàn lại (bagging) (DT vs. RF) để cô lập độ lợi của tập hợp; (ii) bagging vs. tăng cường (boosting) (RF vs. XGBoost) để so sánh các chiến lược tổng hợp; và (iii) tăng cường theo mức vs. theo lá (XGBoost vs. LightGBM) để đánh giá tác động của chiến lược phát triển dưới dữ liệu huấn luyện được tăng cường bằng SMOTE.

3.5 Quy trình Huấn luyện

Quy trình huấn luyện tuân theo một giao thức không rò rỉ (no-leakage) nghiêm ngặt: tất cả các phép biến đổi làm thay đổi dữ liệu (làm sạch, chia tỷ lệ, SMOTE) chỉ được khớp (fitted) riêng trên tập huấn luyện và được áp dụng mà không cần khớp lại cho các tập xác thực và kiểm tra. Điều này giúp loại bỏ hai nguồn phổ biến nhất gây lạm phát điểm số trên CIC-IDS2017: bộ chia tỷ lệ được khớp trên toàn bộ Dataset (làm rò rỉ số liệu thống kê kiểm tra) và SMOTE được áp dụng trước khi chia (làm rò rỉ các điểm kiểm tra tổng hợp bắt nguồn từ dữ liệu huấn luyện).

Quy trình ngoại tuyến diễn ra như sau:

1. **Làm sạch (Clean)**: loại bỏ các hàng chứa `NaN` hoặc $\pm\infty$; loại bỏ các bản sao chính xác.
2. **Lấy mẫu (Sample)**: giới hạn mỗi lớp ở mức 50.000 hàng; gộp các lớp có dưới 500 mẫu vào `Rare_Attack`.
3. **Chia tập (Split)**: Chia theo phân tầng 80/20 train/test (random seed 42).
4. **Chuẩn hóa (Scale)**: Khớp `StandardScaler` chỉ trên các đặc trưng huấn luyện; chuyển đổi cả hai tập.
5. **Mã hóa (Encode)**: Khớp `LabelEncoder` trên các nhãn huấn luyện; chuyển đổi cả hai tập.
6. **SMOTE**: áp dụng Proportional SMOTE (Phần 4.1) chỉ vào tập huấn luyện.

7. **Huấn luyện (Train)**: khớp cả bốn bộ phân loại trên tập huấn luyện được tăng cường với `class_weight=balanced`.
8. **Đánh giá (Evaluate)**: tính điểm mỗi mô hình trên tập kiểm tra độc lập; báo cáo Macro-F_1, ROC-AUC, MCC và Độ chính xác cân bằng.

Không có tìm kiếm siêu tham số nào ngoài các cài đặt mặc định được mô tả trong Phần 3.4 được thực hiện; mục tiêu là một đánh giá duy nhất (single-seed), có thể tái tạo nhằm so sánh công bằng bốn bộ phân loại trong các điều kiện giống hệt nhau.

3.6 Suy luận và Các cân nhắc Triển khai

Vào thời điểm triển khai, mô hình đã được huấn luyện, bộ chia tỷ lệ đã được khớp và bộ mã hóa nhãn được tuần tự hóa (serialised) vào đĩa và được worker suy luận tải lên. Mỗi bản ghi Flow đến được truyền qua cùng các bước EngineerFeatures và Scale đã được áp dụng trong thời gian huấn luyện, đảm bảo rằng không có độ lệch (skew) giữa huấn luyện/phục vụ. Bộ phân loại đã được huấn luyện sau đó sẽ xuất ra một vector xác suất lớp; nhãn dự đoán là lớp có xác suất cao nhất.

Như được trình bày trong Phần 4.6, tất cả các mô hình dựa trên cây đều đạt được > 30.000 Flow mỗi giây trên một lõi CPU duy nhất, thỏa mãn một cách thoải mái mục tiêu thông lượng 10^4 Flow/s. Việc xử lý theo lô siêu nhỏ (micro-batching - thu thập 128 Flow trước khi gọi `predict_proba` một lần) làm tăng thông lượng lên gấp $6-9$ lần so với các cuộc gọi mẫu đơn lẻ với độ trễ bổ sung không đáng kể, làm cho suy luận hàng loạt (batch inference) trở thành mặc định được khuyến nghị cho các đợt triển khai sản xuất. Mô hình LightGBM được tuần tự hóa chỉ chiếm khoảng 5 MB, cho phép triển khai đồng thời với trình trích xuất Flow trên cùng một máy chủ gateway nằm gọn trong ngân sách tài nguyên 512 MB.

4 Thực nghiệm và Kết quả

4.1 Thiết lập Thực nghiệm

Môi trường Tính toán. Tất cả các thử nghiệm được thực hiện trên Google Colab sử dụng runtime chỉ có CPU (Intel Xeon, 2 lõi, ≈12 GB RAM). Không có bộ tăng tốc GPU nào được sử dụng để huấn luyện hoặc suy luận; điều này phản ánh một kịch bản triển khai thực tế trên một gateway biên thông thường. Ngăn xếp phần mềm như sau:

Thành phần	Phiên bản
Python	3.10
scikit-learn	1.4
XGBoost	2.0
LightGBM	4.3
imbalanced-learn	0.12
pandas / NumPy	2.0 / 1.26

Dataset và Tiền xử lý. Kho ngữ liệu CIC-IDS2017 thô được lấy từ Kaggle (`chethuhn/network-intrusion-dataset`), sao chép lại tám tệp CSV có nguồn gốc từ PCAP ban đầu của Viện An ninh Mạng Canada. Bảng 2 tóm tắt tiến trình của Dataset qua từng giai đoạn tiền xử lý.

Table 2. Kích thước Dataset ở mỗi giai đoạn của quy trình tiền xử lý.

Giai đoạn	Số hàng	Ghi chú
Thô (8 tệp CSV)	2.830.743	79 cột bao gồm cả nhãn
Sau khi xóa Inf/NaN	2.827.876	−5.734 hàng
Sau khi xóa trùng lặp	2.520.798	−307.078 hàng
Sau khi giới hạn phân tầng (50k/lớp)	234.187	13 lớp, 78 đặc trưng
Tập huấn luyện (80%)	187.349	phân tách phân tầng
Tập kiểm tra (20%)	46.838	độc lập, không được nhìn thấy khi huấn luyện

Hợp nhất Nhãn. Ba lớp có ít hơn 500 mẫu được hợp nhất thành một lớp giả (pseudo-class) duy nhất là `Rare_Attack`: `Infiltration` (36 Flow), `Web Attack - SQL Injection` (21 Flow), và `Heartbleed` (11 Flow). Tập hợp nhãn kết quả do đó bao gồm 13 lớp: `BENIGN`, `Bot`, `DDoS`, `DoS GoldenEye`, `DoS Hulk`, `DoS Slowhttptest`, `DoS slowloris`, `FTP-Patator`, `PortScan`, `Rare_Attack`, `SSH-Patator`, `Web Attack - Brute Force`, và `Web Attack - XSS`.

Xử lý Mất cân bằng Lớp. Chúng tôi áp dụng chiến lược lấy mẫu kết hợp hai giai đoạn chỉ cho tập huấn luyện:

1. **Giới hạn phân tầng (Stratified cap)**: mỗi lớp được lấy mẫu con tối đa 50.000 mẫu để tránh tình trạng hết bộ nhớ trên runtime Colab.
2. **Proportional SMOTE**: các lớp thiểu số được lấy mẫu tăng cường sử dụng công thức *mục tiêu căn bậc hai* được thiết kế để tránh tạo ra một tỷ lệ mẫu tổng hợp lớn phi thực tế:

$$N_{\text{target}} = \min\Big(\sqrt{N_{\text{maj}} \cdot N_{\text{min}}},\ 10 \times N_{\text{min}},\ N_{\text{maj}}\Big)\,, \tag{3}$$

   trong đó N_{maj} và N_{min} lần lượt là số lượng sau giới hạn của lớp đa số và lớp thiểu số. SMOTE sử dụng $k = 5$ láng giềng gần nhất trong Feature Space huấn luyện. Công thức mục tiêu đảm bảo rằng tỷ lệ tổng hợp không bao giờ vượt quá 90% đối với bất kỳ lớp nào, giữ cho tín hiệu huấn luyện dựa trên các quan sát thực tế.

Cả bốn mô hình đều được huấn luyện với `class_weight='balanced'` bên cạnh SMOTE, ngoại trừ LightGBM xử lý trọng số lớp nội bộ thông qua `is_unbalance=True`. Một seed ngẫu nhiên toàn cục là 42 được sử dụng để phân tách train/test, SMOTE và tất cả các thành phần mô hình ngẫu nhiên.

4.2 Các số liệu Đánh giá

Chúng tôi đánh giá mỗi mô hình trên tập kiểm tra độc lập (46.838 Flow) bằng cách sử dụng các số liệu sau. Do sự phân phối lớp vẫn bị lệch nặng ngay cả sau khi lấy mẫu, chúng tôi coi **Macro-F_1** là tiêu chí lựa chọn mô hình chính.

Accuracy (Độ chính xác) phần trăm các Flow được phân loại đúng. Gây hiểu lầm khi mất cân bằng: một bộ dự đoán chỉ-`BENIGN` tầm thường đạt được ≈80% trên phân phối thô.

Macro-F_1 giá trị trung bình không trọng số của các điểm F_1 theo lớp, mang lại tầm quan trọng như nhau cho các lớp thiểu số như `Bot` và `Rare_Attack`.

Weighted-F_1 giá trị trung bình có trọng số theo hỗ trợ lớp (class-support) của các điểm F_1 theo lớp; bị chi phối bởi `BENIGN` và các lớp tấn công chính.

ROC-AUC (macro OvR) diện tích trung bình dưới đường cong ROC theo phương pháp một-vs-phần còn lại (one-vs-rest) trên tất cả các lớp; đo lường chất lượng xếp hạng độc lập với ngưỡng quyết định.

Balanced Accuracy (Độ chính xác Cân bằng) giá trị recall trung bình theo lớp; hữu ích khi so sánh các mô hình qua các ma trận nhầm lẫn có hình dạng khác nhau.

Hệ số Tương quan Matthews (MCC) một đại lượng vô hướng duy nhất trong $[-1, +1]$ tính đến cả bốn ô của ma trận nhầm lẫn; mạnh mẽ trước cả sự phổ biến (prevalence) và sự khác biệt về quy mô lớp.

Training time (Thời gian huấn luyện) thời lượng huấn luyện theo đồng hồ treo tường trên runtime Colab CPU, được báo cáo để có khả năng tái tạo thực tế.

Một *đường cơ sở BENIGN tầm thường* (luôn dự đoán lớp 0) được bao gồm ngầm định: nó đạt Macro-F_1 khoảng 21% (recall là 1 đối với một lớp, recall là 0 đối với 12 lớp còn lại), minh họa lý do tại sao độ chính xác (accuracy) đơn thuần lại không cung cấp nhiều thông tin.

4.3 Hiệu suất Phát hiện Tổng thể

Bảng 3 và 4 so sánh bốn mô hình ứng viên tương ứng khi không có và có lấy mẫu tăng cường Proportional SMOTE.

Table 3. Hiệu suất trên tập kiểm tra *không có* SMOTE (class_weight='balanced').

Mô hình	Macro-F_1	Weighted-F_1	ROC-AUC	Huấn luyện (s)
XGBoost	**0.9214**	**0.9959**	**0.9997**	112
LightGBM	0.9206	0.9954	**0.9997**	149
Random Forest	0.9202	0.9948	0.9969	62
Decision Tree	0.9092	0.9908	0.9869	7

Table 4. Hiệu suất trên tập kiểm tra *với* Proportional SMOTE.

Mô hình	Macro-F_1	Weighted-F_1	ROC-AUC	Bal. Acc	MCC	Huấn luyện (s)
LightGBM	**0.9241**	0.9955	**0.9997**	**0.9253**	0.9945	212
XGBoost	0.9209	**0.9956**	**0.9997**	0.9163	**0.9947**	157
Random Forest	0.9149	0.9943	0.9996	—	—	125
Decision Tree	0.9068	0.9883	0.9869	—	—	12

Những Quan sát Chính. LightGBM với SMOTE đạt Macro-F_1 cao nhất (0.9241) và Độ chính xác Cân bằng (Balanced Accuracy) cao nhất (0.9253), khiến nó trở thành mô hình tổng thể tốt nhất để phát hiện các lớp tấn công thiểu số một cách công bằng. **XGBoost** bám sát ngay sau đó và có MCC cao nhất (0.9947), cho thấy thứ hạng gần như hoàn hảo trên tất cả các ô của ma trận nhầm lẫn. **Random Forest** cung cấp một đường cơ sở vững chắc (Macro-F_1 = 0.9202 trước SMOTE) với thời gian huấn luyện ngắn nhất trong số các phương pháp tập hợp (62 s), làm cho nó trở thành lựa chọn thiết thực nhất khi khả năng tính toán bị hạn chế. **Cây Quyết định (Decision Tree)**, mặc dù đạt Macro-F_1 90,7%, cho thấy rằng ngay cả một bộ học phi tập hợp đơn giản cũng nắm bắt được phần lớn các tín hiệu phân biệt trong các đặc trưng Flow của CIC-IDS2017.

Tất cả bốn mô hình đều dễ dàng vượt qua mục tiêu Macro-F_1 0,95 đối với các lớp tấn công chủ đạo, được đại diện tốt; Macro-F_1 tổng thể giảm xuống dưới 0,95 do ba lớp thực sự khó (`Web Attack - XSS`, `Web Attack - Brute Force`, và `Rare_Attack`), sẽ được thảo luận chi tiết trong Phần 4.4.

4.4 Phân tích chi tiết theo Lớp

Bảng 5 báo cáo Precision, Recall, và F_1 cho từng lớp đối với mô hình tốt nhất (LightGBM sau Proportional SMOTE) trên tập kiểm tra độc lập.

Các Lớp Mạnh. Sáu lớp đạt được $F_1 = 1.00$ hoàn hảo: `BENIGN`, `DDoS`, `DoS Hulk`, `PortScan`, `FTP-Patator`, và `SSH-Patator`. Các lớp này có số lượng phong phú (BENIGN: giới hạn 50.000; DoS Hulk: giới hạn 50.000) hoặc thể hiện các dấu hiệu thống kê rất đặc trưng trong các đặc điểm cấp độ Flow—DDoS floods khối lượng lớn tạo ra các giá trị `Flow Packets/s` cực hạn, trong khi các cuộc tấn công SSH/FTP brute-force cho thấy một loạt các phiên TCP thời lượng ngắn với các cờ RST lặp lại.

Các Lớp Web Attacks dễ nhầm lẫn. `Web Attack - XSS` và `Web Attack - Brute Force` là cặp vấn đề nhất. Ở cấp độ Flow HTTP, phân phối đặc trưng của chúng chồng chéo lên nhau đáng kể: cả hai đều tạo ra các phiên TCP có độ dài vừa phải, số lượng Packet thấp đến cổng 80/443 và số liệu thống kê IAT của chúng gần như giống hệt nhau. Sự nhầm lẫn được phản ánh qua sự bất đối

Table 5. Các số liệu theo lớp đối với LightGBM + Proportional SMOTE trên tập kiểm tra.

Lớp	**Precision**	**Recall**	F_1	**Thách thức chính**
BENIGN	1.00	1.00	1.00	Số lượng nhiều, mẫu đặc trưng
DDoS	1.00	1.00	1.00	Khối lượng lớn, cờ đặc trưng
DoS Hulk	1.00	1.00	1.00	Mẫu HTTP flood lặp đi lặp lại
PortScan	1.00	1.00	1.00	Mẫu truy cập cổng tuần tự
FTP-Patator	1.00	1.00	1.00	Dấu hiệu xác thực lỗi lặp đi lặp lại
SSH-Patator	1.00	1.00	1.00	Dấu hiệu xác thực lỗi lặp đi lặp lại
DoS GoldenEye	0.99	0.98	0.99	Khối lượng trung bình, trộn lẫn với Hulk
DoS Slowhttptest	0.99	0.97	0.98	Mẫu tốc độ chậm, trùng lặp IAT
DoS slowloris	0.98	0.96	0.97	Hồ sơ IAT tương tự Slowhttptest
Bot	0.93	0.80	0.86	Khối lượng thấp (∼1.9k), tổng hợp nhiều
Web Attack – Brute Force	0.87	0.79	0.83	Tương đồng lớp HTTP với XSS
Web Attack – XSS	0.62	0.86	0.72	Dễ bị nhầm lẫn với Brute Force
Rare_Attack	0.58	0.34	0.43	Gộp các lớp không đồng nhất, ∼90% tổng hợp
Trung bình Macro	**0.92**	**0.90**	**0.92**	
Trung bình có trọng số	**0.996**	**0.996**	**0.996**	

xứng giữa độ chính xác/thu hồi: XSS đạt được recall cao (0,86) nhưng precision thấp (0,62), nghĩa là hầu hết các Flow XSS đều được phát hiện nhưng gần một phần ba số cảnh báo XSS dự đoán thực chất là các Flow Brute Force. Việc kiểm tra cấp độ Payload (payload-level) hoặc đặc trưng entropy URI có khả năng giải quyết hầu hết sự nhầm lẫn này nhưng nằm ngoài phạm vi của phân loại chỉ dựa trên Flow.

Rare_Attack. Lớp giả gộp này (`Infiltration` + `SQL Injection` + `Heartbleed`) đạt được $F_1 = 0.43$ thấp nhất. Nguyên nhân cơ bản có hai phần: (i) ba loại tấn công cấu thành có các dấu hiệu mạng khác nhau về chất, vì vậy nhãn được hợp nhất không mạch lạc về mặt ngữ nghĩa; (ii) khoảng 90% mẫu huấn luyện do SMOTE tạo ra, khiến mô hình không có đủ bằng chứng thực tế. Phần 4.5 định lượng tác động của phần tổng hợp này.

SMOTE vs. Không SMOTE trên Recall Lớp Thiểu số. So sánh các lớp thiểu số trước và sau khi có SMOTE, recall của lớp `Bot` cải thiện từ 0,71 lên 0,80 (+9 pp) và recall của lớp `Rare_Attack` cải thiện từ 0,18 lên 0,34 (+16 pp), xác nhận rằng việc lấy mẫu tăng cường cung cấp một sự gia tăng có ý nghĩa cho các lớp có tỷ lệ hiện diện thấp nhất bất chấp việc tỷ lệ tổng hợp tăng cao.

4.5 Nghiên cứu Cắt bỏ (Ablation Studies)

Để cô lập sự đóng góp của từng lựa chọn thiết kế, chúng tôi thực hiện một loạt các nghiên cứu cắt bỏ, mỗi nghiên cứu sửa đổi một thành phần của quy trình trong khi giữ nguyên các thành phần khác.

(a) Tác động của SMOTE lên Macro-F_1. Bảng 6 báo cáo sự thay đổi trong Macro-F_1 khi Proportional SMOTE được thêm vào dựa trên cơ sở `class_weight=balanced`.

Table 6. ΔMacro-F_1 do Proportional SMOTE đóng góp.

Mô hình	Không SMOTE	Có SMOTE	Δ	Nhận định
LightGBM	0.9206	0.9241	+0.0035	✓ Cải thiện
XGBoost	0.9214	0.9209	−0.0005	≈ Trung lập
Random Forest	0.9202	0.9149	−0.0053	× Hơi suy giảm
Decision Tree	0.9092	0.9068	−0.0024	× Hơi suy giảm

LightGBM là mô hình duy nhất được hưởng lợi nghiêm ngặt từ SMOTE. Chiến lược phân tách dựa trên biểu đồ của nó sử dụng các điểm tổng hợp mới để tinh chỉnh ranh giới các thùng (bin) ở các vùng của lớp thiểu số, mang lại các bề mặt quyết định tốt hơn một cách thực sự. Ngược lại, Random Forest vốn đã áp dụng trọng số `balanced_subsample` tại mọi lần rút mẫu bootstrap; việc thêm các láng giềng tổng hợp gần với bản gốc sẽ tạo ra nhiễu nhãn nhẹ mà không đóng góp thông tin mới, làm giảm nhẹ Macro-F_1. XGBoost gần như không thay đổi ($|\Delta| < 0.001$), chứng tỏ sự mạnh mẽ đối với bước lấy mẫu tăng cường bất kể nó có giúp ích hay không.

(b) Tỷ lệ Tổng hợp vs. Độ tin cậy. Các lớp có tỷ lệ tổng hợp trên 80% cho thấy độ tin cậy bị suy giảm ở F_1 theo lớp. Cụ thể:

- `Bot` ($\approx$ 80% tổng hợp): $F_1 = 0.86$ — chấp nhận được nhưng không hoàn hảo.
- `Web Attack - XSS` ($\approx$ 89% tổng hợp): $F_1 = 0.72$ — suy giảm rõ rệt.
- `Rare_Attack` ($\approx$ 90% tổng hợp): $F_1 = 0.43$ — không đáng tin cậy.

Điều này xác nhận ngưỡng theo nguyên tắc ngón tay cái: các lớp có các mẫu tổng hợp vượt quá 80% trong tổng số mẫu sau SMOTE nên được xử lý một cách thận trọng và các số liệu được báo cáo của chúng nên được chú thích tương ứng.

(c) Sự đồng thuận của cả Bốn Mô hình (Kiểm tra Định tính 30 mẫu). Như một kiểm tra định tính cuối cùng, chúng tôi đã rút ngẫu nhiên 30 Flow thử nghiệm trải rộng trên tất cả 13 lớp và thu được các dự đoán độc lập từ cả bốn mô hình. Kết quả:

- Cả bốn mô hình đều đúng: **25/30** (83%)
- Đa số (3/4) đúng: **0/30** (0%)
- Đa số sai ($\leq$1/4 đúng): **5/30** (17%)

Năm thất bại này đều thuộc về cùng hai lớp khó: `Web Attack - XSS` (bị nhầm lẫn nhất trí với `Web Attack - Brute Force`) và `Rare_Attack` (bị phân tách

giữa `XSS`, `BENIGN`, và `Rare_Attack`). Sự đồng thuận giữa các mô hình này xác nhận rằng sự nhầm lẫn không phải là một tạo tác của bất kỳ bộ học đơn lẻ nào mà vốn có trong Feature Space cấp độ Flow đối với các loại tấn công này.

4.6 Đặc tính Thời gian chạy

Bảng 7 tóm tắt thời gian huấn luyện và độ trễ suy luận ước tính cho mỗi Flow đối với từng mô hình, được đo trên runtime Colab CPU.

Table 7. Thời gian huấn luyện và chi phí suy luận của mỗi mô hình.

Mô hình	T/g huấn luyện (s)	Kích thước tuần tự hóa (MB)	Suy luận theo lô (Flow/s)
LightGBM	212	≈ 5	> 50.000
XGBoost	157	≈ 8	> 40.000
Random Forest	62	≈ 150	> 30.000
Decision Tree	7	< 1	> 200.000

Tất cả các mô hình dựa trên cây đều dễ dàng thỏa mãn mục tiêu thông lượng 10^4 Flow mỗi giây và ngân sách bộ nhớ < 512 MB được định nghĩa ở Phần 3.1. Mô hình tuần tự hóa của Random Forest là nặng nhất ở mức ≈ 150 MB (200 cây chiều sâu tối đa), nhưng nó vẫn nằm trong giới hạn ngân sách bộ nhớ. LightGBM và XGBoost đều rất nhỏ gọn (< 10 MB), khiến chúng trở thành lựa chọn ưu tiên cho các triển khai bị hạn chế về tài nguyên.

Thời gian huấn luyện của LightGBM (212 s với SMOTE) cao hơn một chút so với XGBoost (157 s) do có thêm chi phí xây dựng biểu đồ cho tập huấn luyện được tăng cường. Tuy nhiên, chi phí này chỉ phát sinh một lần khi hoạt động ngoại tuyến; nó không ảnh hưởng đến ngân sách độ trễ suy luận trực tuyến.

4.7 Thảo luận về Các trường hợp Khó

Nhầm lẫn Web Attacks: XSS vs. Brute Force. Sự nhầm lẫn hệ thống giữa `Web Attack - XSS` và `Web Attack - Brute Force` là chế độ lỗi đáng kể nhất trong quy trình của chúng tôi xét về mặt vận hành. Cả hai loại tấn công đều nhắm vào lớp HTTP và tạo ra các Flow có thời lượng, số lượng Packet và phân phối IAT tương tự nhau. Ở cấp độ Flow, tín hiệu phân biệt duy nhất nằm ở các số liệu thống kê dẫn xuất từ Payload khá tinh vi (ví dụ: entropy của các kích thước phản hồi, phân phối độ dài URI) mà CICFlowMeter không nắm bắt được. Cả bốn mô hình trong thử nghiệm đồng thuận đều phân loại sai mẫu XSS thành Brute Force, xác nhận rằng sự nhầm lẫn này không dành riêng cho mô hình nào mà vốn có trong Feature Space. Một biện pháp giảm thiểu thực tế sẽ là gộp hai loại phụ của Web Attacks thành một lớp `Web Attack` duy nhất để tạo cảnh báo, chấp nhận một nhãn thô hơn để đổi lấy khả năng phát hiện đáng tin cậy.

Rare_Attack: Nhóm không đồng nhất. Nhóm `Rare_Attack` gộp ba loại tấn công có dấu hiệu mạng khác nhau về chất: `Infiltration` (Beacon đánh cắp dữ liệu khối lượng thấp), `SQL Injection` (các Flow nặng về HTTP POST) và `Heartbleed` (dị thường ở lớp bản ghi TLS cụ thể). Việc gộp chúng thành một nhãn duy nhất buộc bộ phân loại phải học một ranh giới quyết định duy nhất cho ba phân phối riêng biệt, điều này chắc chắn làm tăng sự nhầm lẫn với cả lớp `BENIGN` và lớp Web Attacks. Thử nghiệm đồng thuận cho thấy hai mô hình dự đoán đúng `Rare_Attack` trong khi hai mô hình còn lại dự đoán là `Web Attack - XSS` và `BENIGN`, phản ánh sự không đồng nhất này. Với nhiều dữ liệu hơn (hoặc các đặc trưng chuyên dụng ở cấp độ Payload), các lớp này sẽ xứng đáng có các nhãn riêng và đánh giá mô hình cá nhân.

Phát hiện Bot. Lớp `Bot` (1.948 mẫu trong ngữ liệu gốc) đạt được $F_1 = 0.86$ với LightGBM sau khi áp dụng SMOTE. Lưu lượng bot trong CIC-IDS2017 được tạo bởi bản phát lại PCAP của botnet Ares, tạo ra các Beacon C2 dựa trên HTTP đặc trưng với thời gian xuất hiện định kỳ. Mức độ recall tương đối cao (0.80) cho thấy mô hình nắm bắt được tính đều đặn về mặt thời gian, nhưng tỷ lệ khoảng 80% dữ liệu tổng hợp đã gây ra một số nhiễu nhãn làm giảm độ chính xác (precision). Việc triển khai IDS với ngưỡng quyết định thấp hơn đối với lớp Bot (đánh đổi với việc FPR trên lưu lượng BENIGN tăng nhẹ) sẽ làm tăng recall về phía giá trị vận hành mong muốn là > 0.95.

5 Thảo luận và Hướng phát triển

5.1 Hạn chế

Mặc dù kết quả thực nghiệm của chúng tôi chứng minh độ chính xác phát hiện cao, một số hạn chế cần được thừa nhận:

- **Độ chệch của Dataset (Dataset bias)**: Dataset CIC-IDS 2017, mặc dù thực tế hơn so với KDD Cup 99, được tạo ra trong một môi trường phòng thí nghiệm được kiểm soát. Lưu lượng mạng trong thế giới thực thể hiện sự đa dạng và nhiễu lớn hơn.
- **Trôi dạt khái niệm (Concept drift)**: Các mẫu lưu lượng mạng phát triển theo thời gian khi các ứng dụng và giao thức mới xuất hiện. Các mô hình được huấn luyện trên dữ liệu năm 2017 có thể bị suy giảm hiệu suất trên lưu lượng hiện tại nếu không được huấn luyện lại định kỳ.
- **Độ mạnh mẽ đối kháng (Adversarial robustness)**: Những kẻ tấn công tinh vi có thể tạo ra lưu lượng được thiết kế đặc biệt để qua mặt các bộ phân loại ML. Chúng tôi chưa đánh giá độ mạnh mẽ đối kháng trong nghiên cứu này.
- **Phát hiện tấn công hiếm gặp**: Bất chấp việc sử dụng SMOTE, các lớp có rất ít mẫu (Heartbleed: 11 Flow, Infiltration: 36 Flow) vẫn khó có thể được phát hiện một cách đáng tin cậy.

5.2 Hướng Phát triển trong Tương lai

1. **Triển khai thời gian thực**: Tích hợp các mô hình đã được huấn luyện vào một quy trình chụp Packet (ví dụ: với Scapy hoặc CICFlowMeter) để phân loại lưu lượng trực tiếp.
2. **Học liên kết (Federated learning)**: Huấn luyện các mô hình IDS qua nhiều tổ chức mà không chia sẻ dữ liệu lưu lượng thô, bảo vệ quyền riêng tư trong khi vẫn được hưởng lợi từ các mẫu tấn công đa dạng.
3. **Tập hợp của các tập hợp (Ensemble of ensembles)**: Kết hợp các dự đoán của Random Forest, XGBoost và DNN thông qua xếp chồng (stacking) hoặc bỏ phiếu (voting) để tận dụng thế mạnh của từng mô hình.
4. **Huấn luyện đối kháng (Adversarial training)**: Tăng cường dữ liệu huấn luyện bằng các mẫu đối kháng để cải thiện độ mạnh mẽ của mô hình chống lại các cuộc tấn công lẩn tránh.
5. **Học chuyển giao (Transfer learning)**: Huấn luyện trước các mô hình trên các Dataset công khai lớn và tinh chỉnh trên lưu lượng dành riêng cho tổ chức để giảm yêu cầu về dữ liệu được gắn nhãn.

6 Kết luận

Bài báo này đã trình bày thiết kế, triển khai và đánh giá một hệ thống phát hiện xâm nhập mạng ứng dụng AI được huấn luyện trên Dataset chuẩn CIC-IDS2017. Chúng tôi đã đánh giá bốn bộ phân loại Machine Learning—LightGBM, XGBoost, Random Forest và Decision Tree—trong hai chế độ xử lý mất cân bằng lớp (chỉ áp dụng trọng số nhạy cảm với chi phí và trọng số nhạy cảm với chi phí kết hợp với Proportional SMOTE), báo cáo Macro-F_1, ROC-AUC, Độ chính xác cân bằng (Balanced Accuracy), MCC và Precision/Recall/F1 cho từng lớp trên một tập kiểm tra độc lập gồm 46.838 Flow trên 13 lớp.

Những phát hiện chính của chúng tôi như sau:

1. **LightGBM với Proportional SMOTE** đạt được sự cân bằng tổng thể tốt nhất giữa việc phát hiện lớp đa số và lớp thiểu số, với Macro-F_1 là 0.9241 và Độ chính xác cân bằng là 0.9253. Chiến lược phân tách theo lá (leaf-wise) dựa trên biểu đồ (histogram) của nó khai thác các mẫu tổng hợp hiệu quả hơn so với tăng cường theo mức (level-wise boosting) (XGBoost) hoặc lấy mẫu có hoàn lại (bagging) (Random Forest), làm cho nó trở thành mô hình được đề xuất cho các triển khai ưu tiên khả năng phát hiện công bằng trên tất cả các loại tấn công.
2. **XGBoost** là mô hình ổn định nhất (MCC = 0.9947), gần như không bị ảnh hưởng bởi việc áp dụng SMOTE hay không ($|\Delta\text{Macro-}F_1| < 0.001$), điều này khiến nó trở thành lựa chọn mặc định an toàn khi người thực hành không chắc chắn liệu việc lấy mẫu tăng cường có mang lại lợi ích hay không.
3. **Sáu trong số mười ba lớp** (BENIGN, DDoS, DoS Hulk, PortScan, FTP-Patator, SSH-Patator) đạt $F_1 = 1.00$ hoàn hảo với LightGBM. Tất cả các lớp này đều có các đặc trưng mức Flow đặc biệt được phân giải tốt bằng cách phân vùng đặc trưng dựa trên cây.

4. **Mất cân bằng lớp vẫn là thách thức trọng tâm.** Ba lớp có ít hơn 500 mẫu huấn luyện thực (Infiltration, SQL Injection, Heartbleed, được gộp chung vào `Rare_Attack`) và hai loại Web Attacks phụ tương tự về mặt ngữ nghĩa chiếm tất cả các lỗi mô hình lớn. Proportional SMOTE cung cấp một mức tăng hữu ích (recall tăng +9–16 phần trăm trên các lớp thiểu số) nhưng không thể khắc phục hoàn toàn sự thiếu hụt tín hiệu khi tỷ lệ tổng hợp vượt quá 80–90%.
5. **Tất cả các mô hình đều thỏa mãn các ràng buộc triển khai** được định nghĩa ở Phần 3.1: các bộ phân loại dựa trên cây đạt thông lượng > 30.000 Flow/s trên CPU thông thường và vừa vặn trong ngân sách bộ nhớ 512 MB, khiến việc triển khai trực tiếp (inline) trên các gateway biên doanh nghiệp trở nên khả thi.

Toàn bộ quy trình—tải dữ liệu, làm sạch, lấy mẫu phân tầng, Proportional SMOTE, huấn luyện mô hình và đánh giá—được triển khai bằng Python với scikit-learn, XGBoost và LightGBM và có thể tái tạo hoàn toàn với một seed ngẫu nhiên cố định là 42.

Hướng phát triển trong tương lai

Một số hướng nghiên cứu vẫn còn mở cho tương lai. Đầu tiên, bốn lớp dễ nhầm lẫn (Web Attack – XSS, Web Attack – Brute Force, và các thành phần của Rare_Attack) sẽ được hưởng lợi từ các đặc trưng cấp độ Payload (payload-level) hoặc độ biểu đồ entropy (URI-entropy) bắt nguồn từ Deep-Packet Inspection (DPI), điều này sẽ cung cấp tín hiệu phân biệt không có ở cấp độ Flow thuần túy. Thứ hai, Online/Continuous Learning với các bản cập nhật mô hình định kỳ sẽ giải quyết được sự trôi dạt khái niệm (concept drift) tất yếu trong các triển khai trong thế giới thực. Thứ ba, việc đánh giá các mô hình được huấn luyện đối phó với các Flow được tạo ra có chủ ý (adversarial flows)—trong đó kẻ tấn công cố tình thay đổi thời gian xuất hiện (inter-arrival times) hoặc kích thước Packet để bắt chước lưu lượng bình thường—sẽ xác định được giới hạn độ mạnh mẽ thực tế của quy trình hiện tại. Cuối cùng, huấn luyện liên kết (federated training) qua nhiều chu vi tổ chức, mà không chia sẻ lưu lượng truy cập thô, có thể cải thiện phạm vi phủ sóng của lớp thiểu số trong khi vẫn bảo vệ được quyền riêng tư của dữ liệu.

References

1. Sharafaldin, I., Habibi Lashkari, A., Ghorbani, A.A.: Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization. In: Proc. 4th Int. Conf. on Information Systems Security and Privacy (ICISSP), pp. 108–116 (2018)
2. Tavallaee, M., Bagheri, E., Lu, W., Ghorbani, A.A.: A Detailed Analysis of the KDD CUP 99 Data Set. In: Proc. IEEE Symp. on Computational Intelligence for Security and Defense Applications (CISDA), pp. 1–6 (2009)
3. Breiman, L.: Random Forests. Machine Learning **45**(1), 5–32 (2001)
4. Chen, T., Guestrin, C.: XGBoost: A Scalable Tree Boosting System. In: Proc. 22nd ACM SIGKDD, pp. 785–794 (2016)
5. Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P.: SMOTE: Synthetic Minority Over-Sampling Technique. JAIR **16**, 321–357 (2002)
6. Vinayakumar, R., Alazab, M., Soman, K.P., Poornachandran, P., Al-Nemrat, A., Venkatraman, S.: Deep Learning Approach for Intelligent Intrusion Detection System. IEEE Access **7**, 41525–41550 (2019)
7. Buczak, A.L., Guven, E.: A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection. IEEE Commun. Surv. Tutor. **18**(2), 1153–1176 (2016)
8. Abadi, M., et al.: TensorFlow: A System for Large-Scale Machine Learning. In: Proc. 12th USENIX OSDI, pp. 265–283 (2016)
9. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.Y.: LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In: Advances in Neural Information Processing Systems (NeurIPS), vol. 30, pp. 3146–3154 (2017)
10. Lashkari, A.H., Gil, G.D., Mamun, M.S.I., Ghorbani, A.A.: Characterization of Tor Traffic using Time based Features. In: Proc. 3rd Int. Conf. on Information Systems Security and Privacy (ICISSP), pp. 253–262 (2017). `https://www.unb.ca/cic/research/applications.html#CICFlowMeter`
11. Roesch, M.: Snort—Lightweight Intrusion Detection for Networks. In: Proc. 13th USENIX LISA Conference, pp. 229–238 (1999)
12. He, H., Bai, Y., Garcia, E.A., Li, S.: ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. In: Proc. IEEE Int. Joint Conf. Neural Networks, pp. 1322–1328 (2008)
13. Lin, T.Y., Goyal, P., Girshick, R., He, K., Doll'ar, P.: Focal Loss for Dense Object Detection. In: Proc. IEEE ICCV, pp. 2980–2988 (2017)
14. Saito, T., Rehmsmeier, M.: The Precision–Recall Plot is More Informative than the ROC Plot when Evaluating Binary Classifiers on Imbalanced Datasets. PLoS ONE **10**(3), e0118432 (2015)